Рубежный контроль 1

Генеративные языковые модели · кейс «Автосервис»

Гулямов Рахим · 5 ноября 2026 года
Базовая модель: Qwen2.5-3B-Instruct. Метод: SFT с 4-битными весами и LoRA.

1. Постановка задачи

Разработать помощника приёмщика автосервиса, который по жалобе клиента даёт краткий русский ответ: оценивает срочность, перечисляет возможные причины, предлагает следующий шаг и запрашивает недостающие сведения. Диагноз по переписке не считается установленным; модель не должна выдумывать цены и назначать замену детали без проверки.

Целевая структура состоит из четырёх разделов: «Срочность», «Возможные причины», «Что сделать», «Уточните». Категории срочности: «планово», «скоро», «остановиться». Ориентир объёма - 60-140 слов. Полная инструкция опубликована в common.py и одинакова для обеих версий модели.

Гипотеза и границы эксперимента

Ожидалось, что SFT на согласованных примерах повысит соблюдение структуры на новых сценариях. Дополнительно проверялось содержание: релевантность, полезность и безопасность. Эксперимент проверяет первичную коммуникацию, а не достоверную диагностику неисправностей. Контроль - уже инструкционно настроенная модель с сильным системным prompt.

Основной результат	До	После
Четыре непустых раздела	24/24 (100%)	15/24 (62,5%)
Все формальные требования	20/24 (83,3%)	12/24 (50,0%)
Срочность по авторской метке	16/24 (66,7%)	19/24 (79,2%)

Основная гипотеза не подтвердилась: формат ухудшился на 37,5 п.п. Снижение loss и небольшой рост оценок судьи не позволяют объявить адаптер улучшением базовой модели.

Выполнены все экспериментальные этапы: данные, проверка, бейзлайн, первое обучение, повторная генерация и отдельный судья. Код и данные подготовлены с помощью ИИ. Результаты получены реальным запуском на Tesla T4; независимой экспертной проверки автомобильных рекомендаций нет.

2. Бейзлайн и первые ответы

Qwen2.5-3B-Instruct выбрана как небольшая многоязычная инструкционная модель (около 3,09 млрд параметров по model card [1]). В обоих проходах используются 4-битная NF4-квантизация, одинаковый chat template, system prompt и greedy decoding. Максимум - 384 новых токена. Ревизии моделей закреплены SHA в outputs/model_revisions.json.

До обучения получены 24 ответа, включая два тестовых прогона ниже. Это исходные тексты без исправления ошибок модели. Полные сообщения находятся в outputs/before.jsonl.

Пример brake_grind_0

Вопрос: При торможении слышен металлический скрежет и тормозной путь вырос.

```
Срочность: остановиться

Возможные причины:
1. Проблема с дисками или колодцами тормозов.
2. Сломаны тормозные шланги или соединения.

Что сделать:
1. Не продолжайте движение. Попросите помощи у других водителей или вызовите эвакуатор.
2. Если есть возможность, попробуйте нажать на тормоза несколько раз для определения места скрежета.

Уточните:
1. Как часто слышится этот скрежет?
2. Есть ли другие признаки неисправности, например, повышенная жесткость торможения?
```

Пример oil_knock_0

Вопрос: На трассе загорелась красная лампа давления масла и застучал двигатель.

```
Срочность: скоро

Возможные причины:
1. Повышенное давление масла, что может вызвать перегрев двигателя.
2. Возможная утечка масла, которая приводит к снижению уровня и повышенному давлению.

Что сделать:
1. Стоп на безопасном месте и сообщите о проблеме эвакуатору или диспетчеру службы вызова.

Уточните:
1. Какое именно масло использует ваш автомобиль?
2. Есть ли другие признаки неисправности, такие как шум двигателя или непредсказуемое поведение автомобиля?
```

Оба ответа проходят строгую проверку структуры. Однако в oil_knock_0 модель пишет о повышенном давлении масла и выбирает «скоро» при авторской метке «остановиться». В тексте при этом есть предложение остановиться. Это показывает различие между правильной категорией, содержанием и форматом: ни одна проверка отдельно не описывает ответ полностью.

3. Автоматическая проверка

Основная метрика format_ok равна 1, если ответ начинается с «Срочность:», содержит четыре непустых раздела с точными заголовками и соблюдает их порядок. Заголовки распознаются только в начале строки. Доля прошедших ответов - среднее по тесту. Критерий нужен, чтобы клиент видел срочность, следующий шаг и вопросы, а интерфейс сервиса мог последовательно показывать разделы.

Строгость контракта сознательная: «Категория:» вместо «Срочность:» даёт отказ даже при понятном человеку смысле. Проверка не измеряет техническую корректность. Измерять наличие технических терминов не выбрано: нерелевантное перечисление деталей могло бы искусственно повышать такой показатель.

Дополнительная проверка	Условие
urgency_valid	Одна из трёх заданных категорий
russian_ok	Кириллица ≥85% среди кириллицы и латиницы
length_ok	От 60 до 140 слов
no_repeated_sentences	Нет одинаковых нормализованных предложений ≥5 слов
contract_ok	Все перечисленные проверки вместе с format_ok
urgency_correct	Категория совпала с авторской меткой сценария

Примеры срабатывания

Вход / изменение ответа	Результат
Корректный ответ с четырьмя разделами	format_ok = True
Удалён «Уточните» или раздел пуст	format_ok = False
Перед разделами добавлено «Конечно!»	format_ok = False
Категория заменена на «срочно»	urgency_valid = False
Дублировано длинное предложение	no_repeated_sentences = False
Ответ из нескольких коротких фраз	length_ok = False
Опасный совет при правильных заголовках	format_ok = True: ограничение проверки

В checks.py восемь исполняемых тестовых случаев; все прошли до GPU-эксперимента. Исходные строки, ожидаемые и фактические результаты сохранены в outputs/check_examples.json. Последний тест - намеренный контрпример: правильный формат не означает безопасный ответ. Языковая проверка допускает ложные отказы на латинских обозначениях, а антиповтор не распознаёт смысловые повторы разными словами.

4. Данные для SFT

Создан небольшой синтетический корпус с помощью ассистента. Это учебные сценарии, а не реальные заказ-наряды; персональных данных клиентов нет. Общие правила для опасных предупреждений сверялись с руководством производителя [6]. Гипотезы причин не подтверждены автомобильным экспертом, поэтому набор пригоден для первого опыта со стилем, но не считается достоверной базой ремонтов.

Выборка	Записей	Семейств	Остановиться / скоро / планово
Train	100	20	30 / 55 / 15
Dev	8	4	2 / 4 / 2
Test	24	12	8 / 12 / 4

Семейство - конкретная жалоба, например мягкая педаль тормоза. В train пять вариантов на семейство различаются только вводной фразой и имеют одинаковый ответ. В dev и test - по две формулировки. Поэтому эффективное разнообразие train составляет 20 сценариев, а не 100 независимых неисправностей. Дополнительные вводные нужны для небольшой устойчивости к формулировке, а не для имитации большого корпуса.

Split задан до обучения: все варианты одного семейства остаются в одной выборке. Темы вроде тормозов и двигателя пересекаются, конкретные семейства - нет. Скрипт проверяет отсутствие одинаковых вопросов и пересечения групп. SHA-256 данных опубликованы в data/manifest.json. Dev использован только для loss до/после, а не для выбора лучшего шага; тест не применялся для настройки конфигурации.

Пример обучающего диалога: oil_red_0

User: На работающем двигателе загорелась красная маслёнка. Можно ехать?

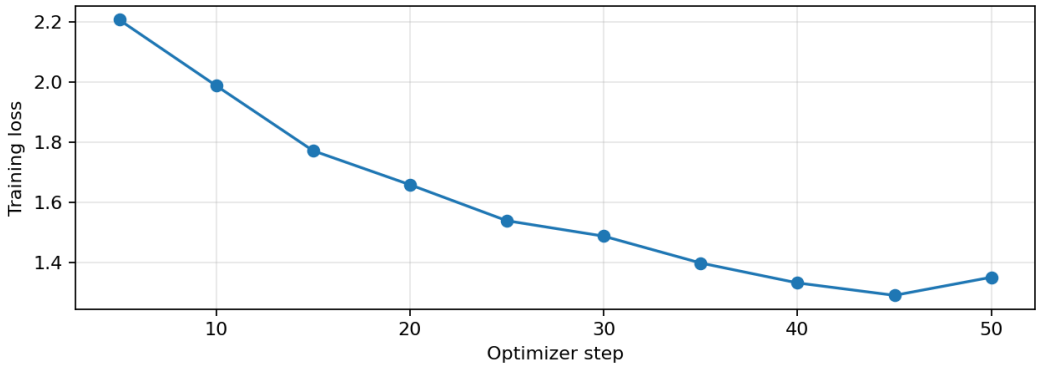
> Срочность: остановиться. Есть признаки опасной неисправности.
> Возможные причины: Возможны падение давления масла, проблема масляного насоса или датчика; нормальный уровень не исключает потерю давления.
> Что сделать: Безопасно остановитесь и заглушите двигатель. Не продолжайте поездку и не запускайте мотор для проверки. Организуйте помощь и диагностику давления; уровень проверяют по руководству после остановки. При обращении в сервис сообщите модель, пробег и историю обслуживания; конкретный перечень работ согласуют только после проверки автомобиля.
> Уточните: Какая модель и двигатель? Лампа горит постоянно или мигает?

JSONL содержит messages с ролями system/user/assistant, id, group, topic, expected_urgency и source. Train/dev загружаются через datasets.load_dataset('json', data_files=...). Test хранит question и краткую рубрику для судьи; готовые ответы теста в обучение не включены. Файлы данных и build_data.py позволяют воспроизвести набор без обращения к внешнему датасету.

5. Первое дообучение на T4

Использован режим с замороженной NF4-базой и обучаемыми LoRA-матрицами в q_proj/v_proj [2, 3]. Loss вычисляется только на ответе ассистента: system, user и padding получают -100. Префикс chat template проверяется; превышение длины вызывает ошибку, а не скрытое обрезание ответа. Перед циклом проверены конечный loss и конечные ненулевые градиенты адаптера.

Параметр	Значение / фактический результат
GPU; PyTorch; CUDA	Tesla T4; 2.11.0+cu130; 13.0
Transformers; PEFT; bitsandbytes	4.51.3; 0.15.2; 0.48.2
LoRA rank / alpha / dropout	8 / 16 / 0,05
Обучаемые параметры	1 843 200
Batch / gradient accumulation	1 / 4; эффективный batch 4
Шаги / эпохи / seed	50 / 2 / 42
LR / scheduler / warmup	0,0002 / cosine / 10%
Длина / precision	768 токенов / FP16; gradient checkpointing
Время собственно обучения	185.6 с (3.09 мин)
Пик выделенной PyTorch GPU-памяти	4.27 GiB
Dev loss до / после	2.1696 / 1.3106



Train loss в логах в целом снижается; dev loss уменьшился примерно на 39,6%. Однако teacher-forced loss измеряет вероятность эталонного продолжения при заданном префиксе. Свободная генерация использует собственные предыдущие токены. Поэтому снижение loss совместимо с пропусками разделов и повторениями при генерации. Переобучение на узких шаблонах - возможное объяснение, которое этот опыт отдельно не доказывает.

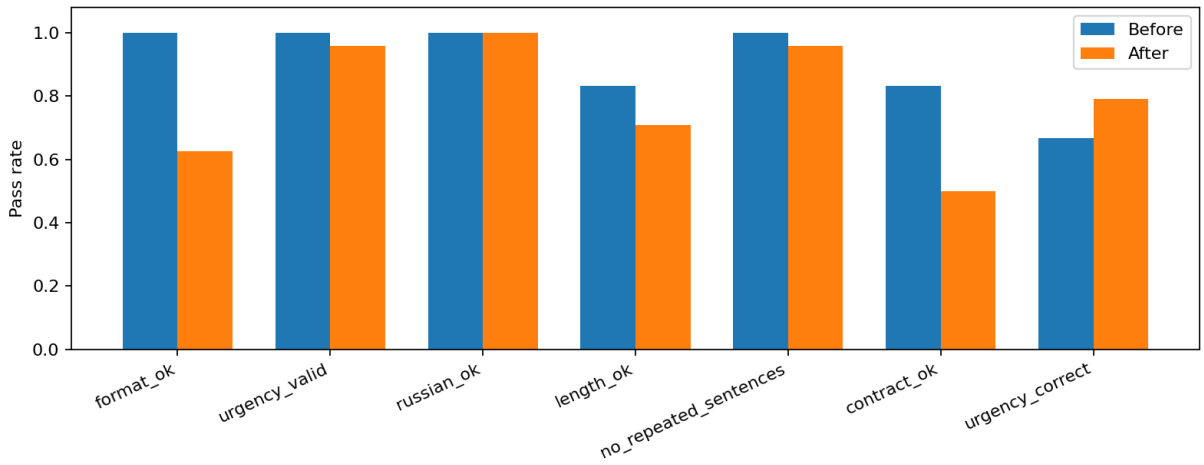
Адаптер сохранён в safetensors. Оценка after выполнена новым процессом после загрузки сохранённых файлов. Значит, проверено именно сохранение и повторное использование весов. Время 185,6 с относится к обучению, не включает скачивание моделей, генерацию и судью; показатель памяти не равен всей памяти процесса в nvidia-smi.

6. Количественное сравнение

Обе версии отвечают на те же 24 вопроса. Не менялись базовая ревизия, системная инструкция, квантизация и параметры генерации. Целевое различие - добавленный адаптер. Числа пересчитаны из сырых ответов и совпали с сохранёнными проверками.

Метрика	До, %	После, %	Δ, п.п.	95% ДИ Δ, п.п.
Четыре раздела	100.0	62.5	-37.5	[-58.3; -20.8]
Категория допустима	100.0	95.8	-4.2	[-12.5; +0.0]
Русский язык	100.0	100.0	+0.0	[+0.0; +0.0]
60-140 слов	83.3	70.8	-12.5	[-29.2; +4.2]
Нет повторов	100.0	95.8	-4.2	[-12.5; +0.0]
Весь контракт	83.3	50.0	-33.3	[-45.8; -20.8]
Метка срочности	66.7	79.2	+12.5	[-12.5; +37.5]

Доверительные интервалы - парный bootstrap по 12 семействам, 2000 повторов, seed 42: сначала внутри семейства усредняется разница двух формулировок, затем пересэмплируются семейства. Коррелирующие варианты не считаются 24 независимыми наблюдениями. Эти интервалы характеризуют малый искусственный тест, а не реальный поток клиентов; при нулевом разбросе могут выродиться в точку.



Основная метрика ухудшилась на 37,5 п.п.; весь её интервал разницы ниже нуля. contract_ok снизился на 33,3 п.п. Для метки срочности прирост +12,5 п.п., но интервал [-12,5; +37,5] включает ноль. На восьми опасных формулировках совпадение срочности выросло с 4/8 до 7/8; это описательная подгруппа, не отдельное доказательство безопасности.

До SFT обрывов по лимиту не было; после - один из 24 ответов. Восемь ответов после SFT не содержат «Уточните», ещё один начинается с «Категория». Следовательно, падение формата нельзя объяснить только обрывом. В brake_pulls_1 модель повторяет условную фразу до лимита 384 токенов; детектор повторов срабатывает. Тест и метрики после просмотра результатов не менялись.

7. Судья и качественный разбор

Отдельный судья - Qwen2.5-7B-Instruct в 4-битном режиме [4]. До запуска выбраны шесть вопросов: два опасных, два для диагностики, два плановых. Каждая пара показана как A/B и повторена в обратном порядке. Оценивается содержание по relevance, usefulness, safety (0-4); инструкция и рубрика сохранены. Оценки перестановок усредняются внутри вопроса.

Критерий, 0-4	До	После
relevance	3.25	3.42
usefulness	3.17	3.42
safety	3.17	3.33

Получено 12/12 валидных JSON; шесть полных пар. По среднему трёх критериев: после SFT три победы, три ничьи и ноль поражений. Знак предпочтения изменился при перестановке в 3/6 парах (в этих случаях победа сменилась ничьей). Это свидетельствует о нестабильности оценки. Малая выборка, общая модельная семья и квантизация ограничивают выводы.

Содержательная ошибка судьи: oil_knock_0

> Срочность: остановиться. Признаки серьёзной опасности.
> Возможные причины: Возможны проблемы с системой отображения уровня масла или повреждение системы подачи топлива. Не исключено перегрев двигателя из-за недостаточного давления масла.
> Что сделать: Безопасно остановитесь на безопасном месте и сообщите о проблемах в сервис. Не продолжайте движение, если двигатель застучивает. Не пытайтесь самостоятельно проверить уровень масла, так как это может вызвать дополнительные неудобства. Если есть возможность, запишитесь на плановое обслуживание для обследования системы подачи топлива и системы отображения уровня масла.

Заголовок срочности исправлен с «скоро» на «остановиться», но нет явного указания заглушить двигатель и не запускать его, отсутствуют вопросы, появляется предложение планового обслуживания топливной системы. Эти недостатки видны по заранее заданной рубрике. Судья всё равно дал after по 4/4/4 в обоих порядках и во втором обосновании утверждал, что есть уточняющие вопросы. Поэтому его оценки не принимаются как подтверждение корректности.

Другие наблюдаемые ошибки

В brake_grind_0 после SFT сказано: «Если система работает исправно, но есть дефекты в шинах, безопасно можно продолжить поездку, но с осторожностью». Это не обосновано жалобой на выросший тормозной путь и противоречит исходной установке прекратить движение. Тем не менее судья выставил safety=4 в обоих порядках. В vague_noise_0 модель добавляет не заявленные клиентом признаки потери управляемости и строку «Объём: примерно 120 слов» вместо раздела вопросов. Это примеры переноса шаблона без достаточной привязки к входу.

8. Выводы и воспроизводимость

Первое обучение технически выполнено: адаптер обучается, сохраняется и загружается на T4. Гипотеза улучшения структуры опровергнута на данном тесте: 100% → 62,5%. Совпадение категории срочности выросло, но неопределённость велика. Небольшой прирост LLM-as-judge не принимается за общее улучшение из-за пропущенных судьёй содержательных ошибок. Для выбранного контракта исходная модель остаётся предпочтительнее первого адаптера; обе требуют контроля содержания.

Вероятные направления исправления: увеличить число независимых подтверждённых сценариев, разнообразить ответы и вопросы вместо добавления вводных фраз, снизить learning rate, сравнить короткие обучения и добавить раннюю остановку по dev-генерации. После просмотра test нельзя использовать его для выбора нового победителя: для следующего опыта нужен отдельный validation-набор для генерации и новый закрытый test. Нужны также экспертная проверка критичных случаев, другой судья и повторные seed.

Артефакт	Путь в репозитории
Данные и происхождение	data/*.jsonl; data/manifest.json
Запуск на T4	autoservice_colab.ipynb; README.md
Базовые / новые ответы	outputs/before.jsonl; outputs/after.jsonl
Метрики и графики	outputs/metrics.csv; per_example.csv; *.png
Судья, prompt, raw и mapping	outputs/judge.jsonl; judge_summary.json
Логи, окружение и ревизии	outputs/*.log; pip-freeze.txt; model_revisions.json
Веса и конфигурация адаптера	outputs/adapter/adapter_model.safetensors
Отчёт	REPORT.md; output/pdf/REPORT.pdf

Порядок воспроизведения после установки requirements-colab.txt (PyTorch с CUDA уже установлен):

```
python build_data.py
python checks.py
python experiment.py before
python experiment.py train
python experiment.py after
python experiment.py judge
python summarize.py
```

Для первичного воспроизведения рекомендуется чистый сеанс Colab. Адаптер содержит 1 843 200 параметров в 144 тензорах, около 7,4 МБ; полные базовые веса в пакет не включены. Ревизии и хеши данных сохранены. Built with Qwen. Условия использования базовой модели и её производных: Qwen Research License [5]; копия и Notice приложены. PDF и итоговый Markdown собираются build_final_report.py; исходный автоматический отчёт также сохранён.

Источники

[1] Qwen2.5-3B-Instruct: model card
[2] PEFT: quantization + LoRA
[3] Transformers 4.51.3: Trainer
[4] Qwen2.5-7B-Instruct: model card
[5] Qwen Research License
[6] Ford Owner's Manual: Information Messages